

Université Hassan II de Casablanca
Faculté des Sciences Ben M'Sick (FSBM)
Département de Mathématiques et Informatique

RAPPORT TECHNIQUE

Master Sciences
Spécialité : Intelligence Artificielle

Prédiction de la Solubilité Moléculaire (LogS)

par Apprentissage Automatique
Projet de fin Module : MACHINE LEARNING

Réalisé par :

Souhail El karem
Abdssalam Safadi

Encadrant :

M. El Habib Ben Lhmar
Co-encadrant : M. Oussama Kaich

Année Universitaire 2025 — 2026

REMERCIEMENTS

Nous tenons à exprimer notre sincère gratitude à notre encadrant M. El Habib Ben Lhmar pour ses conseils avisés, sa disponibilité constante et son encadrement rigoureux tout au long de ce projet. Sa guidance a été déterminante dans l'orientation des choix méthodologiques et dans la rigueur scientifique du travail accompli.

Nous remercions également M. Oussama Kaich, co-encadrant, pour ses précieuses remarques et son soutien technique. Nos remerciements vont aussi à l'ensemble des enseignants de la Faculté des Sciences Ben M'Sick, Université Hassan II de Casablanca, pour la qualité de la formation en Intelligence Artificielle.

Enfin, nous remercions les équipes de recherche ayant constitué et mis à disposition le dataset AqSolDB sur la plateforme Kaggle, sans lequel ce projet n'aurait pu être réalisé.

RÉSUMÉ

Ce rapport technique présente le développement d'un système de prédiction de la solubilité aqueuse (LogS) de molécules organiques par apprentissage automatique. Le projet exploite le dataset AqSolDB (9 982 molécules), extrait des descripteurs moléculaires via RDKit, compare quatre algorithmes de régression supervisée et déploie le meilleur modèle dans une interface Streamlit interactive.

Les résultats montrent que XGBoost obtient les meilleures performances avec un coefficient de détermination R^2 de 0,7947 sur le jeu de test et un RMSE de 1,0551 LogS, surpassant significativement la régression linéaire ($R^2 = 0,570$). L'interface Streamlit permet la prédiction en temps réel à partir d'une notation SMILES.

Mots-clés : Machine Learning, Solubilité moléculaire, LogS, AqSolDB, XGBoost, RDKit, Morgan Fingerprints, Streamlit.

ABSTRACT

This technical report presents the development of a machine learning system for predicting the aqueous solubility (LogS) of organic molecules. The project leverages the AqSolDB dataset (9,982 molecules), extracts molecular descriptors via RDKit, compares four supervised regression algorithms, and deploys the best model in an interactive Streamlit interface.

Results show that XGBoost achieves the best performance with a coefficient of determination R^2 of 0.7947 on the test set and an RMSE of 1.0551 LogS, significantly outperforming linear regression ($R^2 = 0.570$). The Streamlit interface enables real-time prediction from SMILES notation.

Keywords: Machine Learning, Molecular solubility, LogS, AqSolDB, XGBoost, RDKit, Morgan Fingerprints, Streamlit.

TABLE DES MATIÈRES

INTRODUCTION GÉNÉRALE.....	1
CHAPITRE 1 — RÉSUMÉ EXÉCUTIF ET CONTEXTE DU PROJET	2
1.1 Résumé Exécutif.....	2
1.2 Problématique.....	2
1.3 Importance de la Solubilité Moléculaire	2
1.4 Objectifs du Projet.....	3
1.5 Contributions	3
CHAPITRE 2 — PRÉSENTATION DU DATASET AQSOLDB.....	4
2.1 Description Générale	4
2.2 Structure des Données	4
2.3 Variable Cible : LogS.....	4
CHAPITRE 3 — PRÉTRAITEMENT ET EXTRACTION DES CARACTÉRISTIQUES.....	6
3.1 Nettoyage et Suppression des Colonnes.....	6
3.2 Flux de Traitement RDKit.....	6
3.3 Descripteurs Moléculaires (10 features).....	6
3.4 Morgan Fingerprints (256 bits, radius=2)	6
3.5 Construction Finale	7
CHAPITRE 4 — ANALYSE EXPLORATOIRE ET ARCHITECTURE TECHNIQUE ...	8
4.1 Analyse Exploratoire des Données.....	8
4.1.1 Matrice de Corrélation des Descripteurs	8
4.2 Architecture Technique	9
4.2.1 Stack Logicielle	9
4.2.2 Pipeline Global	9
CHAPITRE 5 — MODÈLES, RÉSULTATS ET ANALYSE	10
5.1 Modèles de Machine Learning	10
5.1.1 Régression Linéaire (Baseline).....	10
5.1.2 Random Forest.....	10
5.1.3 Support Vector Regression (SVR)	10
5.1.4 XGBoost	10
5.2 Métriques d'Évaluation.....	11
5.3 Validation Croisée	11
5.4 Comparaison Train vs Test.....	11
5.5 Analyse de l'Overfitting.....	12
5.6 Analyse Approfondie : XGBoost	12

5.6.1 Valeurs Réelles vs Prédictions	12
5.6.2 Importance des Variables	13
5.6.3 Analyse des Résidus	14
CHAPITRE 6 — INTERFACE STREAMLIT ET DÉPLOIEMENT	16
6.1 Architecture de l'Interface	16
6.2 Page Principale — Saisie SMILES	16
6.3 Résultat de Prédiction.....	16
6.4 Descripteurs Moléculaires	17
6.5 Règle des 5 de Lipinski	17
CHAPITRE 7 — LIMITATIONS ET PERSPECTIVES.....	19
7.1 Limitations Identifiées.....	19
7.2 Perspectives d'Amélioration	19
7.3 Graph Neural Networks.....	19
7.4 Déploiement Industriel	19
CONCLUSION GÉNÉRALE	21
BIBLIOGRAPHIE	22
ANNEXES	23
Annexe A — Extrait du Code Python : Extraction des Descripteurs RDKit	23
Annexe B — Interprétation des Seuils de Solubilité.....	23

LISTE DES FIGURES

- Figure 1 — Distribution de la variable cible Solubility (LogS) et Boxplot
- Figure 2 — Matrice de corrélation des descripteurs moléculaires RDKit
- Figure 3 — Scores R^2 en Validation Croisée (KFold k=5) avec barres d'erreur
- Figure 4 — Comparaison R^2 Train/Test et RMSE par modèle
- Figure 5 — Valeurs réelles vs Prédictions sur le jeu de test — 4 modèles (n=1 996)
- Figure 6 — Top 20 features les plus importantes dans XGBoost (gain normalisé)
- Figure 7 — Analyse des Résidus du modèle XGBoost
- Figure 8 — Interface Streamlit — Page principale avec saisie SMILES et exemples
- Figure 9 — Résultat de prédiction pour la Caféine : LogS = -1,5742 (Soluble)
- Figure 10 — Descripteurs moléculaires calculés automatiquement (Caféine)
- Figure 11 — Vérification de la Règle des 5 de Lipinski — Caféine

LISTE DES TABLEAUX

- Tableau 1 — Résumé des indicateurs clés du projet
- Tableau 2 — Description des colonnes du dataset AqSolDB
- Tableau 3 — Descripteurs moléculaires calculés par RDKit et leur pertinence
- Tableau 4 — Construction finale de la matrice de features
- Tableau 5 — Stack logicielle du projet
- Tableau 6 — Hyperparamètres des modèles de Machine Learning
- Tableau 7 — Comparaison complète des métriques (★ = meilleur modèle)
- Tableau 8 — Analyse du risque d'overfitting (seuil $\Delta R^2 > 0,10$)
- Tableau 9 — Interprétation chimique des features les plus importantes
- Tableau 10 — Pistes d'amélioration et performances attendues

LISTE DES ABRÉVIATIONS

ML : Machine Learning (Apprentissage Automatique)

LogS : Logarithme décimal de la solubilité aqueuse (mol/L)

RDKit : Open-Source Cheminformatics Software Library

SMILES : Simplified Molecular Input Line Entry System

R² : Coefficient de détermination (métrique d'évaluation)

RMSE : Root Mean Squared Error (Erreur quadratique moyenne)

MAE : Mean Absolute Error (Erreur absolue moyenne)

EDA : Exploratory Data Analysis (Analyse exploratoire des données)

CV : Cross-Validation (Validation croisée)

SVR : Support Vector Regression

RF : Random Forest (Forêt aléatoire)

ADMET : Absorption, Distribution, Métabolisme, Excrétion, Toxicité

TPSA : Topological Polar Surface Area (Surface polaire topologique)

QED : Quantitative Estimate of Drug-likeness

FP : Fingerprints (Empreintes moléculaires)

INTRODUCTION GÉNÉRALE

La chimie computationnelle connaît une révolution profonde grâce à l'essor des méthodes d'apprentissage automatique. Parmi les propriétés physicochimiques les plus critiques dans le développement pharmaceutique, la solubilité aqueuse occupe une place centrale : elle conditionne directement l'absorption, la biodisponibilité et l'efficacité thérapeutique des molécules actives.

Ce rapport présente le développement d'un système complet de prédiction de la solubilité aqueuse (LogS) de molécules organiques. En exploitant le dataset de référence AqSolDB (9 982 composés) et des représentations moléculaires riches extraites via la bibliothèque RDKit, quatre algorithmes de régression supervisée ont été comparés et évalués selon des critères rigoureux.

Le rapport est structuré en sept chapitres : présentation du contexte et du dataset, prétraitement et extraction des caractéristiques, analyse exploratoire et architecture technique, modélisation et résultats, analyse approfondie du meilleur modèle (XGBoost), déploiement de l'interface Streamlit, et enfin limitations et perspectives d'amélioration.

CHAPITRE 1 — RÉSUMÉ EXÉCUTIF ET CONTEXTE DU PROJET

1.1 Résumé Exécutif

Ce projet s'inscrit dans le domaine de la chimie computationnelle assistée par l'intelligence artificielle. L'objectif central est de prédire automatiquement la solubilité aqueuse (LogS) de molécules organiques à partir de leur représentation structurale SMILES, en utilisant des algorithmes de Machine Learning entraînés sur le dataset de référence AqSolDB.

Tableau 1 — Résumé des indicateurs clés du projet

Indicateur	Valeur
Dataset	AqSolDB — 9 982 molécules organiques (Kaggle)
Variable cible	LogS — logarithme de la solubilité aqueuse (mol/L)
Descripteurs RDKit	10 descripteurs physicochimiques
Morgan Fingerprints	256 bits, radius = 2
Total features	266 features après concaténation
Modèles comparés	Linear Regression, Random Forest, SVR, XGBoost
Meilleur modèle	XGBoost (RandomizedSearchCV optimisé)
R ² _test	0,7947
RMSE_test	1,0551 LogS
Overfitting	$\Delta R^2 = 0,074 < 0,10$ — Généralisation satisfaisante
Interface	Streamlit — prédiction interactive en temps réel

1.2 Problématique

La solubilité aqueuse constitue l'une des propriétés physicochimiques les plus déterminantes dans le développement de nouveaux médicaments. Sa mesure expérimentale est coûteuse, chronophage et difficilement scalable pour des bibliothèques de millions de composés. La question centrale de ce projet est : peut-on prédire avec précision le LogS d'une molécule organique à partir de descripteurs calculables automatiquement ?

1.3 Importance de la Solubilité Moléculaire

La solubilité aqueuse, exprimée en LogS (logarithme décimal de la concentration molaire à saturation), conditionne directement l'absorption gastro-intestinale, la biodisponibilité et le profil ADMET des molécules actives. On estime que plus de 40 % des candidats médicaments échouent en phase clinique en raison d'une solubilité insuffisante.

1.4 Objectifs du Projet

- Construire un pipeline ML reproductible : EDA → prétraitement → features → modèles → évaluation → déploiement.
- Extraire des représentations moléculaires riches via RDKit (descripteurs physicochimiques + Morgan Fingerprints).
- Comparer quatre algorithmes de régression supervisée sur le même jeu de données.
- Prévenir le surapprentissage par sélection de features et régularisation.
- Déployer le meilleur modèle dans une interface Streamlit interactive.

1.5 Contributions

Ce travail apporte : (1) un pipeline d'extraction de features combinant descripteurs et Morgan Fingerprints, (2) une comparaison systématique de quatre algorithmes avec optimisation des hyperparamètres, (3) une analyse rigoureuse du surapprentissage, et (4) une interface utilisateur accessible via navigateur web.

CHAPITRE 2 — PRÉSENTATION DU DATASET AQSOLDB

2.1 Description Générale

AqSolDB est la plus grande base de données curatée de solubilité aqueuse disponible en accès libre, publiée par Sorkun et al. (2019). Elle contient 9 982 composés organiques uniques avec leurs valeurs de solubilité mesurées expérimentalement à 25°C et pH neutre. C'est le dataset de référence dans la littérature pour les benchmarks de prédiction de LogS.

2.2 Structure des Données

Tableau 2 — Description des colonnes du dataset AqSolDB

Variable	Type	Description
ID	Identifiant	Identifiant unique de la molécule
Name	Texte	Nom chimique IUPAC
SMILES	Texte	Représentation structurale linéaire
InChI / InChIKey	Texte	Identifiants IUPAC (supprimés)
Solubility	Numérique	LogS — variable cible (mol/L)
SD	Numérique	Écart-type des mesures expérimentales
Ocurrences	Entier	Nombre de mesures indépendantes
Group	Catégorie	Groupe de validation (supprimé)
MolWt, MolLogP...	Numérique	Descripteurs RDKit précalculés (17)

2.3 Variable Cible : LogS

La variable LogS représente $\log_{10}(S)$ où S est la solubilité en mol/L. Les valeurs s'étendent de -13,17 à +2,14, avec une moyenne de -2,89 et un écart-type de 2,37. Une valeur de LogS > -1 indique une très bonne solubilité ; LogS < -4 signale une molécule peu soluble.

Analyse de la Variable Cible : Solubility (LogS)




Figure 1 — Distribution de la variable cible Solubility (LogS) et Boxplot

CHAPITRE 3 — PRÉTRAITEMENT ET EXTRACTION DES CARACTÉRISTIQUES

3.1 Nettoyage et Suppression des Colonnes

Les colonnes ID, Name, InChI, InChIKey, SD, Occurrences et Group sont supprimées car elles ne contiennent pas d'information structurale prédictive. Les SMILES invalides sont filtrés via RDKit (Chem.MolFromSmiles). Le dataset final contient 9 982 molécules valides.

3.2 Flux de Traitement RDKit

```
SMILES → Chem.MolFromSmiles() → Objet Mol RDKit →  
Descriptors.xxx(mol) → Vecteur numérique
```

3.3 Descripteurs Moléculaires (10 features)

Tableau 3 — Descripteurs moléculaires calculés par RDKit et leur pertinence

Descripteur	Définition	Pertinence pour LogS
MolWt	Poids moléculaire (g/mol)	Les grandes molécules sont moins solubles
MolLogP	Coefficient LogP octanol/eau	Corrélation négative forte ($r = -0,73$)
TPSA	Surface polaire topologique (Ψ)	Corrélation positive (polarité → solubilité)
NumHDonors	Donneurs de liaisons H	Interactions hydrogène avec l'eau
NumHAcceptors	Accepteurs de liaisons H	Hydrophilie moléculaire
NumRotatableBonds	Liaisons rotatives	Flexibilité conformationnelle
NumAromaticRings	Cycles aromatiques	Hydrophobicité planaire
FractionCSP3	Fraction C sp3	Saturation → tendance à la solubilité
HeavyAtomCount	Atomes lourds	Taille moléculaire globale
QED	Drug-likeness quantitatif	Profil ADMET global

3.4 Morgan Fingerprints (256 bits, radius=2)

Les Morgan Fingerprints génèrent une représentation binaire de 256 dimensions encodant la présence ou l'absence de sous-structures chimiques dans un rayon de 2 liaisons autour de chaque atome. Ils capturent des informations topologiques locales inaccessibles aux descripteurs globaux.

3.5 Construction Finale

Tableau 4 — Construction finale de la matrice de features

Source	Nombre	Type
Descripteurs RDKit	10	Numérique continu
Morgan Fingerprints (256 bits)	256	Binaire (0/1)
TOTAL	266	Matrice $\mathbb{R}^{(9982 \times 266)}$

Après la génération des descripteurs moléculaires et des fingerprints, plusieurs étapes de sélection ont été appliquées afin de conserver uniquement les variables les plus pertinentes.

Tout d'abord, les variables présentant une faible variance ont été supprimées à l'aide de **VarianceThreshold**, car elles apportent peu d'information au modèle.

Ensuite, les variables fortement corrélées ($r > 0,95$) ont été éliminées afin de réduire la redondance et la complexité des données.

Enfin, la méthode **SelectKBest** avec **f_regression** a été utilisée pour sélectionner les 50 caractéristiques les plus importantes pour la prédiction de la solubilité.

À l'issue de ce processus, la matrice finale contient environ **50 variables optimales**, permettant d'améliorer les performances et la capacité de généralisation des modèles.

CHAPITRE 4 — ANALYSE EXPLORATOIRE ET ARCHITECTURE TECHNIQUE

4.1 Analyse Exploratoire des Données

4.1.1 Matrice de Corrélation des Descripteurs

La matrice de corrélation révèle que MolLogP est le prédicteur linéaire le plus fort. HeavyAtomCount et MolWt sont fortement corrélés ($r = 0,95$), justifiant leur filtrage. TPSA et NumHAcceptors présentent une corrélation positive avec LogS, reflétant l'effet favorable des groupes polaires sur la solubilité.




Figure 2 — Matrice de corrélation des descripteurs moléculaires RDKit

4.2 Architecture Technique

4.2.1 Stack Logicielle

Tableau 5 — Stack logicielle du projet

Outil	Version	Rôle
Python	3.10+	Langage principal
RDKit	2023.09	Descripteurs et Morgan FP
Pandas / NumPy	2.0+ / 1.24+	Manipulation des données
Scikit-learn	1.3+	Pipeline ML, sélection, évaluation
XGBoost	2.0+	Gradient boosting optimisé
Streamlit	1.28+	Interface utilisateur web
Joblib	1.3+	Sérialisation du modèle

4.2.2 Pipeline Global

Le pipeline de prédiction comprend plusieurs étapes successives : chargement du dataset, validation des SMILES, calcul des descripteurs moléculaires et des fingerprints Morgan, sélection des caractéristiques, division des données en ensembles d'entraînement (80 %) et de test (20 %), standardisation des variables, entraînement des modèles de Machine Learning, validation croisée K-Fold (k=5), optimisation des hyperparamètres via RandomizedSearchCV, évaluation des performances, puis déploiement du meilleur modèle dans une interface Streamlit.

CHAPITRE 5 — MODÈLES, RÉSULTATS ET ANALYSE

5.1 Modèles de Machine Learning

5.1.1 Régression Linéaire (Baseline)

Modèle de référence. Combine linéairement les features : $\hat{y} = \beta_0 + \sum \beta_i x_i$. Rapide et interprétable, mais incapable de capturer les relations non-linéaires structure-propriété.

5.1.2 Random Forest

Ensemble de N arbres de décision entraînés sur des sous-échantillons bootstrap. La prédiction est la moyenne des sorties individuelles. Hyperparamètres : `n_estimators=200`, `max_depth=10`, `min_samples_leaf=5`, `max_features='sqrt'`.

5.1.3 Support Vector Regression (SVR)

Cherche une fonction $f(x)$ déviant au plus de ϵ des cibles. Noyau RBF. Paramètres : `C=10`, `epsilon=0,1`, `gamma='scale'`. Nécessite une standardisation préalable des features.

5.1.4 XGBoost

Implémentation optimisée du Gradient Boosting avec régularisation L1/L2 intégrée, sous-échantillonnage stochastique et parallélisation. Paramètres : `n_estimators=300`, `max_depth=5`, `learning_rate=0,05`, `reg_alpha=0,1`, `reg_lambda=1,0`.

Tableau 6 — Hyperparamètres des modèles de Machine Learning

Modèle	Hyperparamètre	Valeur
Random Forest	<code>n_estimators / max_depth</code>	200 / 10
Random Forest	<code>min_samples_leaf / max_features</code>	5 / 'sqrt'
XGBoost	<code>n_estimators / max_depth</code>	300 / 5
XGBoost	<code>learning_rate / subsample</code>	0,05 / 0,8
XGBoost	<code>reg_alpha / reg_lambda</code>	0,1 / 1,0
SVR	<code>C / epsilon / kernel</code>	10 / 0,1 / RBF

5.2 Métriques d'Évaluation

$$\text{RMSE} = \sqrt{[(1/n) \cdot \sum (y_i - \hat{y}_i)^2]} \quad (1)$$

$$\text{MAE} = (1/n) \cdot \sum |y_i - \hat{y}_i| \quad (2)$$

$$R^2 = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2 \quad (3)$$

5.3 Validation Croisée

XGBoost obtient le meilleur R^2 CV moyen ($0,7642 \pm 0,0203$), suivi de SVR ($0,7129 \pm 0,0212$) et Random Forest ($0,7090 \pm 0,0135$). La faible variance confirme la stabilité des modèles.




Figure 3 — Scores R^2 en Validation Croisée (KFold $k=5$) avec barres d'erreur

5.4 Comparaison Train vs Test




Figure 4 — Comparaison R² Train/Test et RMSE par modèle

Tableau 7 — Comparaison complète des métriques (★ = meilleur modèle)

Modèle	RMSE train	RMSE test	MAE test	R ² train	R ² test	ΔR ²
Linear Reg.	1,612	1,527	1,160	0,540	0,570	+0,030
Random Forest	0,854	1,086	0,746	0,871	0,783	+0,088
XGBoost ★	0,861	1,055	0,732	0,869	0,795	+0,074
SVR	0,824	1,179	0,833	0,880	0,744	+0,136

5.5 Analyse de l'Overfitting

Tableau 8 — Analyse du risque d'overfitting (seuil ΔR² > 0,10)

Modèle	R ² _train	R ² _test	ΔR ²	Statut
Linear Reg.	0,540	0,570	+0,030	✓ Underfitting
Random Forest	0,871	0,783	+0,088	✓ Correct
XGBoost ★	0,869	0,795	+0,074	✓ Meilleur équilibre
SVR	0,880	0,744	+0,136	⚠ Overfitting détecté

5.6 Analyse Approfondie : XGBoost

5.6.1 Valeurs Réelles vs Prédictions

XGBoost (R² = 0,7947, RMSE = 1,0551) présente la plus forte concentration des points autour de la diagonale parfaite. La régression linéaire montre un étalement important pour les molécules très peu solubles.

Valeurs Réelles vs Prédictions - Jeu de Test




Figure 5 — Valeurs réelles vs Prédictions sur le jeu de test — 4 modèles ($n=1\,996$)

5.6.2 Importance des Variables

MolLogP domine avec une importance de 0,1803 ($3\times$ la 2ème feature). Plusieurs bits Morgan (fp_189, fp_81, fp_223) apparaissent dans le top 5, confirmant l'apport des fingerprints pour capturer des sous-structures non représentées par les descripteurs globaux.




Figure 6 — Top 20 features les plus importantes dans XGBoost (gain normalisé)

Tableau 9 — Interprétation chimique des features les plus importantes

Feature	Importance	Interprétation chimique
MolLogP	0,1803	Hydrophobicité — molécules lipophiles moins solubles
fp_189, fp_81	0,063/0,052	Sous-structures aromatiques / groupes électroattracteurs
MolWt	0,0500	Taille — effet stérique sur la solvation
FractionCSP3	0,0273	Saturation — carbones sp3 favorisent la solubilité
TPSA	0,0268	Surface polaire — interactions directes avec H ₂ O
NumHDonors	0,0256	Liaisons H — améliore la miscibilité avec l'eau
NumAromaticRings	0,0247	Aromaticité — associée à l'insolubilité (π -stacking)

5.6.3 Analyse des Résidus

L'histogramme des résidus montre une distribution quasi-normale centrée sur 0, confirmant l'absence de biais systématique. Une légère hétéroscédasticité est visible pour les molécules très peu solubles ($\text{LogS} < -6$), attendue vu la sous-représentation de cette région.

Analyse des Résidus - Meilleur Modèle : XGBoost




Figure 7 — Analyse des Résidus du modèle XGBoost — Distribution et résidus vs prédictions

CHAPITRE 6 — INTERFACE STREAMLIT ET DÉPLOIEMENT

6.1 Architecture de l'Interface

Le modèle XGBoost est sérialisé via joblib (model.pkl) et chargé en cache (@st.cache_resource). L'interface calcule les descripteurs à la volée pour chaque SMILES saisi, garantissant la cohérence avec le pipeline d'entraînement.

6.2 Page Principale — Saisie SMILES

L'interface principale permet à l'utilisateur de saisir une notation SMILES et d'obtenir instantanément la valeur de LogS prédite, accompagnée d'une interprétation qualitative de la solubilité. Des molécules exemples (Aspirine, Caféine, Glucose, Ibuprofène, Benzène) sont proposées en raccourci.



Figure 8 — Interface Streamlit — Page principale avec saisie SMILES et exemples

6.3 Résultat de Prédiction

Pour la Caféine ($C_8H_{10}N_4O_2$) : LogS prédit = -1,5742 $\rightarrow$ $2,67 \times 10^{-2}$ mol/L $\rightarrow$ Soluble. Valeur expérimentale : -1,44 LogS. Erreur = 0,13 LogS, bien inférieure au RMSE moyen de 1,055 LogS.



Figure 9 — Résultat de prédiction pour la Caféine : LogS = -1,5742 (Soluble)

6.4 Descripteurs Moléculaires

L'interface affiche automatiquement les 10 descripteurs RDKit calculés pour la molécule saisie (poids moléculaire, LogP, TPSA, donneurs H, accepteurs H, liaisons rotatives, cycles aromatiques, QED). Cette fonctionnalité permet de comprendre les propriétés sous-jacentes à la prédiction.




Figure 10 — Descripteurs moléculaires calculés automatiquement (Caféine)

6.5 Règle des 5 de Lipinski

Vérification automatique des 4 critères de drug-likeness. La Caféine respecte toutes les règles : $\text{MolWt}=194,2 \leq 500$ ✓, $\text{LogP}=-1,03 \leq 5$ ✓, $\text{HBD}=0 \leq 5$ ✓, $\text{HBA}=3 \leq 10$ ✓.




Figure 11 — Vérification de la Règle des 5 de Lipinski — Caféine

CHAPITRE 7 — LIMITATIONS ET PERSPECTIVES

7.1 Limitations Identifiées

- RMSE de 1,05 LogS : erreur d'un facteur ~ 11 sur la solubilité réelle — acceptable pour le criblage mais insuffisant pour la formulation précise.
- Hétéroscédasticité pour les molécules très peu solubles ($\text{LogS} < -6$) : sous-représentation dans le dataset.
- Dépendance à RDKit : nécessite conda avec le canal conda-forge, complexifiant le déploiement cloud.
- Absence de représentation 3D : les descripteurs ne capturent pas la conformation tridimensionnelle.
- Conditions standardisées uniquement (25°C, pH neutre) : le modèle n'est pas généralisable à d'autres conditions.

7.2 Perspectives d'Amélioration

Tableau 10 — Pistes d'amélioration et performances attendues

Amélioration	RMSE attendu	Description
Descripteurs RDKit enrichis (+200)	$\sim 0,92$	Chi, Kappa, EState, VSA
Stacking RF + XGBoost + SVR	$\sim 0,85$	StackingRegressor + méta-modèle Ridge
Graph Neural Networks (GNN)	$\sim 0,60$	PyTorch Geometric — état de l'art
Transformer moléculaire	$\sim 0,55$	ChemBERTa, MolBERT
API REST + Docker + Cloud	N/A	FastAPI + Hugging Face Spaces

7.3 Graph Neural Networks

Les GNN constituent la voie la plus prometteuse. En modélisant la molécule comme un graphe (atomes = nœuds, liaisons = arêtes), le GNN apprend automatiquement les représentations les plus pertinentes. Des architectures GCN ou MPNN ont démontré RMSE $\approx 0,60$ LogS sur AqSolDB, soit 43 % d'amélioration par rapport à XGBoost.

7.4 Déploiement Industriel

L'exposition via une API REST (FastAPI), la containerisation Docker et le déploiement sur Hugging Face Spaces permettraient un accès public universel. Une fonctionnalité de prédiction par batch (upload CSV) constitue une évolution naturelle de l'interface Streamlit.

CONCLUSION GÉNÉRALE

Ce projet avait pour objectif de développer un système complet de prédiction de la solubilité aqueuse (LogS) par Machine Learning, en exploitant des descripteurs moléculaires RDKit et le dataset AqSolDB de référence.

Tous les objectifs ont été atteints. XGBoost a été sélectionné comme meilleur modèle ($R^2_{\text{test}} = 0,7947$, $\text{RMSE} = 1,055 \text{ LogS}$, $\Delta R^2 = 0,074$). L'interface Streamlit offre une prédiction interactive en temps réel avec affichage des descripteurs et vérification de la règle de Lipinski.

Ce travail démontre l'efficacité du Machine Learning pour la chimie computationnelle. La combinaison de descripteurs physicochimiques interprétables et de Morgan Fingerprints structuraux permet de capturer des relations non-linéaires complexes entre structure et solubilité.

Les Graph Neural Networks, avec $\text{RMSE} \approx 0,60 \text{ LogS}$ sur AqSolDB, représentent la prochaine étape naturelle. L'intégration de valeurs SHAP pour l'explainability et le déploiement via API REST complèteraient ce projet vers une solution industrialisable.

BIBLIOGRAPHIE

- [1] Sorkun, M. C., Khetan, A., & Er, S. (2019). AqSolDB, a curated reference set of aqueous solubility. *Scientific Data*, 6(1), 143.
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *KDD 2016*, 785–794.
- [3] Delaney, J. S. (2004). ESOL: Estimating Aqueous Solubility Directly from Molecular Structure. *J. Chem. Inf. Comput. Sci.*, 44(3), 1000–1005.
- [4] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [5] RDKit: Open-Source Cheminformatics. (2023). <https://www.rdkit.org/>
- [6] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825–2830.
- [7] Lipinski, C. A., et al. (2001). Experimental and computational approaches to estimate solubility. *Adv. Drug Deliv. Rev.*, 46, 3–26.
- [8] Morgan, H. L. (1965). The Generation of a Unique Machine Description for Chemical Structures. *J. Chem. Doc.*, 5(2), 107–113.
- [9] Bergstra, J., & Bengio, Y. (2012). Random Search for Hyper-Parameter Optimization. *JMLR*, 13, 281–305.
- [10] Streamlit Inc. (2023). Streamlit — The fastest way to build and share data apps. <https://streamlit.io/>
- [11] Lovric, M., et al. (2021). Non-stationary features in ML models for solubility prediction. *J. Cheminformatics*, 13(1), 7.
- [12] Duvenaud, D., et al. (2015). Convolutional Networks on Graphs for Learning Molecular Fingerprints. *NeurIPS 2015*.

ANNEXES

Annexe A — Extrait du Code Python : Extraction des Descripteurs

RDKit

```
from rdkit import Chem from rdkit.Chem import Descriptors, AllChem import
numpy as np def compute_features(smiles): mol =
Chem.MolFromSmiles(smiles) if mol is None: return None
desc = [Descriptors.MolWt(mol), Descriptors.MolLogP(mol),
Descriptors.TPSA(mol), Descriptors.NumHDonors(mol)] fp =
AllChem.GetMorganFingerprintAsBitVect(mol, radius=2, nBits=256)
return np.concatenate([desc, fp.ToList()])
```

Annexe B — Interprétation des Seuils de Solubilité

LogS	Solubilité (mol/L)	Interprétation
> -1	> 0,1 mol/L	Très soluble
-1 à -2	0,01 – 0,1 mol/L	Soluble
-2 à -4	0,0001 – 0,01 mol/L	Modérément soluble
-4 à -6	10^{-6} – 10^{-4} mol/L	Peu soluble
< -6	< 10^{-6} mol/L	Insoluble